

PROYECTO BIG DATA

Radar electoral de comentarios en vivo

Informe de arquitectura, procesamiento NLP
y operación distribuida

Alumno	Sixto Caceres Terrones
Plataforma	AWS EMR, S3, Kafka, Flink y Spark
Interfaz	Dashboard web local
Fecha	30 de junio de 2026
Versión	Arquitectura distribuida vigente

Índice general

Resumen ejecutivo	III
1. Arquitectura del clúster	1
1.1. Topología física	1
1.2. Roles y disponibilidad	1
2. Arquitectura detallada del pipeline	2
2.1. Diagrama de componentes	2
2.2. Flujo de una sesión	2
2.3. Topics y contratos	3
3. Instalación, configuración y arranque	4
3.1. Prerrequisitos	4
3.2. Configuración	4
3.3. Arranque desde cero	4
3.4. Validación	4
3.5. Scripts después de reiniciar una sesión	5
3.6. Parada segura	5
4. Datasets y fuentes	6
4.1. YouTube Live Chat electoral peruano	6
4.2. OffendES	6
4.3. Consideraciones éticas	6
5. Técnicas NLP	8
5.1. Normalización streaming	8
5.2. Reglas lingüísticas locales	8
5.3. Spark ML con OffendES	8
5.4. Scoring híbrido	8
6. Documentación de los 10 jobs	9
6.1. Idempotencia y control	9
6.2. Cinco jobs Flink	9
6.3. Cinco jobs Spark	9
7. Reporte de métricas	10
7.1. Validación distribuida de 2,000 eventos	10
7.2. Métricas ML	10
7.3. Métricas del corpus completo	10
7.4. Cadencia del dashboard	11
8. Interfaz gráfica funcional	12

9. Conclusiones	13
A. Trazabilidad documental	14
B. Rutas principales	15

Resumen ejecutivo

El sistema analiza comentarios de YouTube Live Chat asociados al discurso electoral peruano. La fuente durable reside en Amazon S3; un productor Python reproduce los registros como flujo y los publica en un clúster Kafka KRaft de tres nodos. Desde el topic `raw_youtube_chat`, cinco jobs Flink realizan análisis de baja latencia y Spark procesa rangos disjuntos de 1,000 registros. Los resultados streaming regresan a Kafka y los productos batch se almacenan como Parquet en S3 Curated.

La solución combina dos familias de técnicas NLP: reglas lingüísticas específicas del contexto peruano y modelos Spark ML entrenados con OffendES. Las reglas aportan señales explicables de terruqueo, fraude electoral, instituciones, actores, insultos y discriminación; el modelo aporta clasificación general de ofensividad en español. El nivel de riesgo híbrido evita interpretar la predicción ML cruda como una verdad política.

La validación distribuida registró quorum Kafka de tres voters, cero particiones offline, cinco consumidores Flink, batches Spark sin solapamiento y salidas S3 separadas por rango. El dashboard ofrece control de arranque y parada, feeds en vivo, contadores, batches y diagnóstico. Mientras existe una sesión AWS activa, el estado principal se muestra como **conectado** con foco verde; las advertencias técnicas permanecen visibles en el panel detallado.

Capítulo 1

Arquitectura del clúster

1.1. Topología física

La plataforma separa el bus de eventos del cómputo. Esta decisión evita que una aplicación Spark intensiva compita directamente con Kafka por memoria y CPU.

Capa	Nodo o clúster	Rol	Servicios
Datos	Amazon S3	Fuente durable	CSV Raw, modelos OffendES, Parquet Curated, reportes y agregados.
Eventos	Primary, nodo 1	Entrada y coordinación	Broker/controller 1, producer Python, monitor, SSH y descubrimiento EMR.
Eventos	Core, nodo 2	Réplica Kafka	Broker/controller 2, réplica e ISR.
Eventos	Core, nodo 3	Réplica Kafka	Broker/controller 3, réplica e ISR.
Streaming	Primer worker	Baja latencia	Flink 1.17.1, cinco jobs, YARN y acceso privado a Kafka.
Batch	Workers compute	Cómputo por rangos	Spark 3.4.1 sobre YARN, launchers, locks y estados JSON atómicos.
Control	Máquina local	Plano de control	Node.js, API HTTP, dashboard, SSH/SCP y llave PEM local.

1.2. Roles y disponibilidad

- Los tres nodos Kafka combinan los roles `broker`, `controller`. El quorum utiliza puerto 9093 y el tráfico de clientes usa 9092.
- Los topics operativos tienen tres particiones, factor de replicación 3 y `min.insync.replicas=2`.
- El primary descubre dinámicamente los DNS privados de los core nodes; la llave privada no se copia a AWS.
- Flink usa grupos estables. Si un job cae, su offset confirmado permite medir el lag y reanudar.
- Spark mantiene rangos inmutables e idempotentes. La política segura es `SPARK_MAX_CONCURRENCY=1`.

Capítulo 2

Arquitectura detallada del pipeline

2.1. Diagrama de componentes




Figura 2.1: Pipeline distribuido vigente. Flink y Spark son consumidores independientes del mismo topic RAW.

2.2. Flujo de una sesión

1. El operador inicia el dashboard y pulsa **Conectar AWS**.
2. El bootstrap descubre tres nodos Kafka, prepara KRaft y crea los topics.
3. El productor lee el CSV de S3, añade `event_id` y `row_number`, y publica en Kafka.
4. Flink procesa continuamente y confirma offsets por grupo.
5. Al existir un múltiplo completo de 1,000 eventos, Spark agenda el rango siguiente.
6. Spark valida el tamaño exacto, aplica reglas, ML e híbrido, y escribe rutas exclusivas en S3.
7. El dashboard consulta deltas y salud sin consumir ni modificar los offsets de los jobs.

2.3. Topics y contratos

Topic	Productor	Contenido
raw_youtube_chat	Producer Python	Comentario original, metadatos de origen, número de fila y timestamp de ingestión.
nlp_stream_results	Flink 1–4	Normalización, métricas por ventana, señales políticas y polarización por actor.
alerts_polarization	Flink 5	Alertas explicables con tipo, severidad, actor, reglas y puntaje local.
nlp_batch_results	Reservado	Integración batch opcional; la salida vigente de Spark se conserva en S3.

Capítulo 3

Instalación, configuración y arranque

3.1. Prerrequisitos

- EMR_PRIMARY con tres instancias RUNNING.
- Uno o más EMR_WORKERS con Hadoop, Spark 3.4.1 y Flink 1.17.1.
- Conectividad privada entre clústeres y permisos S3.
- Node.js 18 o superior, PowerShell o Git Bash, SSH/SCP y AWS CLI.
- `final.pem` y un archivo `.env` local, ambos fuera de Git.

3.2. Configuración

```
EMR_PRIMARY=ec2-primary.compute-1.amazonaws.com
EMR_WORKERS=ec2-compute-1.compute-1.amazonaws.com
DATA_SIZE=30000
SPARK_BATCH_SIZE=1000
SPARK_MAX_CONCURRENCY=1
```

3.3. Arranque desde cero

```
cd emr_kafka_setup/dashboard
./start_dashboard.sh
# Windows: .\start_dashboard.ps1
```

Se abre <http://127.0.0.1:8787> y se pulsa **Conectar AWS**. Para un bootstrap directo y controlado:

```
./scripts/bootstrap_emr_streaming.sh \
--limit 2000 \
--producer-delay-ms 10 \
--reset-topics
```

3.4. Validación

```
./scripts/aws_status_from_aws.sh \
--data-size 2000 \
--spark-batch-size 1000 \
--spark-max-concurrency 1
```

```
./scripts/spark_status_from_aws.sh --max-concurrency 1
./scripts/pipeline_health_from_aws.sh
```

3.5. Scripts después de reiniciar una sesión

Si solo se cerró la terminal local, se vuelve a ejecutar el dashboard. Si también deben restaurarse producer, monitor y jobs, conservando topics y offsets:

```
./scripts/restart_services_after_session.sh
# Windows:
.\scripts\restart_services_after_session.ps1
```

Estos wrappers invocan `bootstrap_emr_streaming.sh --no-reset-topics`. Para empezar una sesión limpia se usa **Detener plataforma** y luego **Conectar AWS**.

3.6. Parada segura

```
./scripts/stop_emr_streaming.sh
```

La parada cancela aplicaciones YARN, drivers Spark, jobs Flink, producer, monitor y brokers. No elimina el CSV, los modelos ni los productos S3.

Capítulo 4

Datasets y fuentes

4.1. YouTube Live Chat electoral peruano

El dataset principal contiene 160,464 comentarios deduplicados. Fue recolectado de chats públicos de YouTube asociados a transmisiones y discusión electoral peruana mediante `yt-dlp`. El archivo durable es:

```
s3://figuretibucket/data/raw/youtube/youtube_lake.csv
```

Las columnas relevantes se organizan así:

Columna	Uso en el pipeline
source_file	Archivo de chat del que proviene el registro.
video_id	Identificador de la transmisión de YouTube.
timestamp_text	Marca temporal legible dentro del chat.
timestamp_usec	Tiempo original en microsegundos.
video_offset_msec	Posición relativa usada para agregados históricos.
author	Autor público del mensaje.
message_raw / message_clean	Texto original y versión preparada para análisis.

La fuente no incluye etiquetas humanas de ofensividad; por esa razón no se usa como corpus supervisado de entrenamiento.

4.2. OffendES

OffendES es el corpus externo etiquetado para investigación de lenguaje ofensivo en español. La copia de trabajo se conserva en S3:

```
s3://figuretibucket/dataset/offendES/train.parquet
s3://figuretibucket/dataset/offendES/validation.parquet
s3://figuretibucket/dataset/offendES/test.parquet
```

Fuentes públicas: <https://huggingface.co/datasets/fmplaza/offendes> y el artículo <https://aclanthology.org/2021.ranlp-1.123/>. El mapeo binario usa etiquetas 0/1 como ofensivo y 2/3 como no ofensivo. El modelo multiclase conserva las cuatro categorías analíticas.

4.3. Consideraciones éticas

- Las reglas y predicciones son señales analíticas, no juicios definitivos sobre personas.
- Términos étnicos, regionales o políticos requieren contexto humano.

- Los identificadores de usuarios no deben usarse para persecución, perfilado sensible ni decisiones automatizadas.
- El cambio de dominio entre OffendES y chat político peruano obliga a reportar incertidumbre.

Capítulo 5

Técnicas NLP

5.1. Normalización streaming

Flink selecciona `message_clean` o el mensaje `raw`, convierte a minúsculas, reduce espacios y conserva trazabilidad con `topic`, partición y `offset`. La normalización es deliberadamente ligera para sostener baja latencia.

5.2. Reglas lingüísticas locales

Se aplican expresiones y diccionarios multilabel para terrorismo, fraude, instituciones electorales, actores, polarización, lenguaje discriminatorio, insultos y spam. Cada activación aporta etiquetas y un `local_risk_score`. La salida explica la razón del riesgo.

5.3. Spark ML con OffendES

El pipeline supervisado usa `RegexTokenizer`, eliminación de stopwords, `HashingTF`, IDF y regresión logística. Se entrenan un clasificador binario y otro multiclase. El entrenamiento es offline; la inferencia sobre cada batch carga modelos persistidos.

5.4. Scoring híbrido

La señal final combina confianza ML y reglas:

- **Bajo:** no hay evidencia fuerte.
- **Medio:** predicción incierta o reglas moderadas.
- **Alto:** confianza elevada y/o combinación local de riesgo.

Este enfoque compensa la sobredetección del modelo general y la cobertura limitada de reglas puramente locales.

Capítulo 6

Documentación de los 10 jobs

6.1. Idempotencia y control

Cada batch usa un identificador como `batch_0001000`. El launcher conserva un lock y un estado JSON remoto. Si el estado ya existe no vuelve a escribir la salida; el reproceso requiere `--force`. Antes de avanzar, el servidor verifica que todos los rangos anteriores estén **done**.

6.2. Cinco jobs Flink

N.º	Job	Salida	Descripción
F1	Normalización	Resultados NLP	Un resultado principal por comentario; confirma offsets en <code>flink-job1-normalize</code> .
F2	Métricas por ventana	Resultados NLP	Ventanas de tiempo con volumen, autores únicos, longitud media, vacíos y spam aparente.
F3	Señales políticas	Resultados NLP	Reglas de terruqueo, fraude, instituciones, política, discriminación e insultos.
F4	Polarización por actor	Resultados NLP	Agrupar menciones, insultos y señales por actor en ventanas temporales.
F5	Alertas de riesgo	Alertas	Emite solo casos que superan condiciones de alerta, con severidad y explicación.

6.3. Cinco jobs Spark

N.º	Job	Entrada/salida	Descripción
S1	Kafka Raw Ingest	Kafka → Parquet	Lee offsets y filtra <code>row_number</code> por rango; exige exactamente 1,000 filas.
S2	Reglas locales	Parquet → reglas	Genera flags multilabel, score local y reporte de distribución.
S3	Entrenamiento OffendES	OffendES → modelos	Entrena y persiste clasificadores binario y multiclase con Spark ML. Se ejecuta offline.
S4	Inferencia OffendES	Parquet + modelos → ML	Aplica ambos modelos a comentarios Kafka y conserva probabilidades y clases.
S5	Híbrido y agregados	Reglas + ML → Curated	Calcula nivel y razón de riesgo, agrega métricas y produce reportes S3.

Capítulo 7

Reporte de métricas

7.1. Validación distribuida de 2,000 eventos

Métrica	Resultado
Voters Kafka / leader	3 / activo
Factor de réplica / minimum ISR	3 / 2
Particiones under-replicated	0
Particiones offline	0
raw_youtube_chat	2,000
nlp_stream_results	4,021
alerts_polarization	10
Lag total Flink	0
Nodos YARN compute	2
Batches Spark completos / fallidos	2 / 0
Solapamiento de <code>event_id</code> entre batches	0

Cuadro 7.1: Evidencia registrada en la validación distribuida.

7.2. Métricas ML

Modelo	Accuracy	Macro F1
OffendES binario	0.838968	0.749030
OffendES multiclase	0.771939	0.548677

La inferencia ML cruda marcó 53.25 % como ofensivo en YouTube, pero 60.31 % de las predicciones se concentró en confianza 0.50–0.70. Por cambio de dominio, ese porcentaje no se adopta como conclusión final.

7.3. Métricas del corpus completo

Sobre 160,464 comentarios, las reglas registraron 4.05 % de terruqueo, 5.03 % de fraude, 4.46 % de instituciones electorales, 31.36 % de menciones políticas, 5.70 % de polarización y 3.21 % de insulto general. El score local promedio fue 0.5698, con máximo 8.

El scoring híbrido produjo:

Nivel	Porcentaje
Bajo	52.37 %
Medio	42.44 %
Alto	5.19 %

7.4. Cadencia del dashboard

Dato	Frecuencia objetivo	Fuente
RAW, eventos y normalizados	3 s	live delta
Estado Spark	3 s	estados remotos
Inventario Kafka y threshold	5 s	offsets Kafka
Salud integral	5 s	snapshot + SSH

Flink normalizados se obtiene del offset confirmado por `flink-job1-normalize`. De este modo el contador representa progreso real, queda limitado por RAW y no aumenta al recargar o volver a entregar eventos visuales.

Capítulo 8

Interfaz gráfica funcional

La interfaz web implementa:

- arranque asíncrono, progreso y parada distribuida;
- chat RAW y eventos Flink en vivo;
- tarjetas de muestra válida, normalizados, alertas y filas Spark;
- búsqueda y filtros de comentarios;
- polarización por actor y alertas;
- inventario de batches y comentarios ofensivos por batch;
- quorum Kafka, topics, lag, YARN, workers y acciones de recuperación.

El estado principal usa tres situaciones:

1. **sin conexión:** no existe sesión activa;
2. **consultando:** se está obteniendo el primer diagnóstico;
3. **conectado:** sesión AWS activa, texto y foco verde.

Una condición técnica degradada no cambia el encabezado a “desconectado”: se conserva en las acciones de diagnóstico. Si Kafka deja de responder, el último estado válido permanece visible y la plataforma nunca se reinicia automáticamente.

Capítulo 9

Conclusiones

1. La separación entre Kafka y compute mejora el aislamiento de recursos y permite escalar el procesamiento sin comprometer el bus.
2. Los grupos Flink estables y los rangos Spark disjuntos proporcionan trazabilidad reproducible desde Kafka hasta S3.
3. El modelo OffendES aporta capacidad supervisada, pero el cambio de dominio impide usar su salida cruda como conclusión política.
4. Las reglas locales hacen explícitas las señales peruanas; el scoring híbrido ofrece una interpretación más defendible.
5. La operación requiere parada confirmada y concurrencia Spark controlada. La idempotencia evita relanzamientos por recargas del navegador.
6. El dashboard ya es funcional como plano de control y observabilidad. El contador normalizado se basa ahora en offsets confirmados, no en mensajes visuales repetidos.

Limitaciones y trabajo futuro

- Incorporar anotación humana peruana para medir precisión local y sesgo.
- Separar modelos de toxicidad, odio, ofensividad y polarización.
- Persistir series de latencia extremo a extremo para percentiles p50/p95/p99.
- Automatizar creación y terminación de clústeres con infraestructura como código.
- Añadir autenticación al plano de control si deja de ser exclusivamente local.

Apéndice A

Trazabilidad documental

La arquitectura vigente se documenta en `README.md`, `architecture.md`, `README_AWS_SETUP.md`, `docs/comandos_levantar_desde_cero.md` y los documentos de `emr_kafka_setup/docs`. Los reportes de pruebas pequeñas se conservan como evidencia histórica y están marcados para no contradecir la política actual.

Apéndice B

Rutas principales

```
emr_kafka_setup/dashboard/server.js  
emr_kafka_setup/dashboard/app.js  
emr_kafka_setup/dashboard/scripts/bootstrap_emr_streaming.sh  
emr_kafka_setup/dashboard/scripts/stop_emr_streaming.sh  
emr_kafka_setup/flink/jobs/FlinkKafkaStreamingJobs.java  
emr_kafka_setup/spark/jobs/  
doc/informe_final.tex
```